



Materia: Ciber física e
inteligencia artificial

Actividad: U2A4 Splits reducibles
de un dataset abierto

Nombre: Diego Alberto Alcaraz González

Docente: Osbaldo Aragón Banderas

Fecha: 15/04/2026



Contenido

Introducción	1
Marco Teórico	2
Importancia de los datos en la inteligencia artificial	2
División de datasets (<i>data splitting</i>).....	2
Sobreajuste (<i>overfitting</i>) y generalización	3
Desarrollo	5
Dataset usado.....	5
Código en Jupyter (visual).....	6
Separación de datos por entrenamiento y pruebas	7
Conclusión.....	8
Bibliografía.....	9



Introducción

En la actualidad, la inteligencia artificial y el aprendizaje automático se han convertido en herramientas fundamentales para el análisis de datos en múltiples áreas, como la salud, la educación y la tecnología. Estos sistemas permiten identificar patrones, realizar predicciones y apoyar la toma de decisiones a partir de grandes volúmenes de información. Sin embargo, el desempeño de los modelos de inteligencia artificial depende en gran medida de la calidad y el tratamiento adecuado de los datos utilizados durante su desarrollo. En este sentido, el manejo de datasets y su correcta preparación representan una etapa esencial dentro del flujo de trabajo en ciencia de datos.

Uno de los procesos más importantes en esta preparación es la división del dataset en subconjuntos, conocida como *data splitting*. Esta técnica consiste en separar los datos en conjuntos de entrenamiento y prueba, permitiendo que el modelo aprenda a partir de una parte de la información y sea evaluado con datos que no ha visto previamente. Este procedimiento es fundamental para garantizar que los resultados obtenidos sean confiables y reflejen el comportamiento real del modelo en situaciones prácticas. Sin esta separación, sería difícil determinar si el modelo realmente ha aprendido patrones útiles o si simplemente ha memorizado los datos originales. El objetivo principal de este trabajo es comprender la importancia de los *splits* dentro del desarrollo de modelos de inteligencia artificial, así como aplicar estos conceptos en un caso práctico. De esta manera, se busca no solo adquirir conocimientos teóricos, sino también desarrollar habilidades técnicas relacionadas con el manejo de datos, la preparación de información y la evaluación de modelos, elementos clave en el campo de la ciencia de datos.



Marco Teórico

Importancia de los datos en la inteligencia artificial

La inteligencia artificial (IA) y el aprendizaje automático (*machine learning*) se fundamentan en el uso de datos como elemento principal para el desarrollo de modelos predictivos y de clasificación. Un *dataset* es un conjunto estructurado de datos que contiene información organizada en filas y columnas, donde cada fila representa una observación y cada columna una característica o variable. Estas variables pueden ser numéricas o categóricas, y en muchos casos incluyen una variable objetivo que el modelo busca predecir. La calidad de los datos, incluyendo su limpieza, consistencia y representatividad, influye directamente en el desempeño de los modelos, ya que datos incompletos o sesgados pueden generar resultados poco confiables (Géron, 2022).

En la práctica, el proceso de ciencia de datos no solo implica el uso de algoritmos, sino también una etapa crucial de preparación de datos. Esta fase incluye la recolección, limpieza, transformación y división de los datos. Sin una adecuada preparación, incluso los modelos más avanzados pueden producir resultados deficientes. Por ello, el manejo adecuado de datasets es considerado una de las habilidades fundamentales en el desarrollo de sistemas de inteligencia artificial.

(Géron, 2022) páginas 74-77

División de datasets (*data splitting*)

Uno de los procedimientos más importantes en el flujo de trabajo de aprendizaje automático es la división del dataset, conocida como *data splitting*. Este proceso consiste en separar el conjunto de datos en diferentes subconjuntos que cumplen funciones específicas durante el entrenamiento y evaluación del modelo. Generalmente, se utilizan tres subconjuntos: entrenamiento (*train*), validación (*validation*) y prueba (*test*). El conjunto de entrenamiento se emplea para que el modelo aprenda los patrones presentes en los datos, mientras que el conjunto de



validación se utiliza para ajustar los hiperparámetros y optimizar el modelo. Por último, el conjunto de prueba permite evaluar el desempeño final con datos que el modelo no ha visto previamente (Goodfellow, Bengio, & Yoshua Courville, 2016).

La división de datos es esencial porque permite simular un entorno real en el que el modelo se enfrenta a información nueva. Sin esta separación, sería imposible determinar si el modelo realmente ha aprendido patrones generalizables o si simplemente ha memorizado los datos originales. De esta forma, el *data splitting* se convierte en una herramienta clave para validar la eficacia de los modelos de inteligencia artificial.

(Goodfellow, 2016) página 16

Sobreajuste (*overfitting*) y generalización

El sobreajuste, conocido como *overfitting*, es uno de los principales problemas en el aprendizaje automático. Ocurre cuando un modelo se ajusta excesivamente a los datos de entrenamiento, capturando no solo los patrones relevantes, sino también el ruido o las irregularidades específicas de ese conjunto de datos. Como resultado, el modelo presenta un excelente desempeño en el conjunto de entrenamiento, pero falla al enfrentarse a nuevos datos.

La correcta división del dataset permite detectar este problema al comparar el rendimiento del modelo entre los conjuntos de entrenamiento y prueba. Si existe una gran diferencia entre ambos, es probable que el modelo esté sobreajustado. En contraste, un modelo que generaliza adecuadamente mantiene un desempeño consistente en ambos conjuntos, lo que indica que ha aprendido patrones útiles y aplicables a datos no vistos (James, Witten, Hastie, & Tibshirani, 2021).

(James, 2021) Tema 3



Proporciones y reproducibilidad en los splits

Las proporciones utilizadas para dividir un dataset pueden variar dependiendo del tamaño del conjunto de datos y del problema a resolver. Sin embargo, algunas configuraciones comunes incluyen divisiones de 70/30, 80/20 o 90/10 entre entrenamiento y prueba. Estas proporciones buscan equilibrar la cantidad de datos disponibles para el aprendizaje del modelo y la evaluación de su desempeño.

Un aspecto importante en este proceso es la reproducibilidad, la cual se logra mediante el uso de una semilla fija (*random_state*). Al establecer una semilla, se garantiza que la división de los datos sea siempre la misma al ejecutar el código, lo que facilita la comparación de resultados y la validación de experimentos. Herramientas como la función `train_test_split` de la librería `scikit-learn` permiten implementar estas divisiones de manera sencilla y controlada (Géron, 2022).

(Géron, 2022) Páginas 82

División estratificada y balance de clases

En problemas de clasificación, es común que las clases estén desbalanceadas, es decir, que una clase tenga muchas más muestras que otra. En estos casos, una división aleatoria simple podría generar subconjuntos con distribuciones desiguales, afectando negativamente la evaluación del modelo. Para solucionar este problema, se utiliza la división estratificada, la cual mantiene la proporción de clases en los conjuntos de entrenamiento y prueba. La estratificación es especialmente importante en aplicaciones sensibles, como la detección de enfermedades o el análisis de datos sociales, donde un mal balance podría conducir a conclusiones incorrectas. Al preservar la distribución original de los datos, se obtiene una evaluación más justa y representativa del desempeño del modelo.



Importancia de la evaluación del modelo

La evaluación de modelos es una etapa crítica en el desarrollo de sistemas de inteligencia artificial. Gracias a la división en conjuntos de entrenamiento y prueba, es posible medir el rendimiento del modelo mediante métricas como precisión, exactitud, recall o F1-score. Estas métricas permiten determinar si el modelo es adecuado para su implementación en escenarios reales. Sin una evaluación adecuada, los resultados obtenidos podrían ser engañosos, lo que afectaría la confiabilidad del sistema. Por esta razón, el uso de *splits* bien definidos no solo es una buena práctica, sino un requisito esencial en cualquier proyecto de aprendizaje automático.

Desarrollo

Dataset usado




Figura 1: Dataset usado para la practica



Código en Jupyter (visual)

```
import pandas as pd
import os
from sklearn.model_selection import train_test_split

# cargar dataset
df = pd.read_csv("C:/Users/Diego/Downloads/Tues_Mental_Health_Dataset.csv")

df.head()
# Información general del dataset
print(df.info())

# class 'pandas.core.frame.DataFrame'
RangeIndex: 1200 entries, 0 to 1199
Data columns (total 13 columns):
 #   column                non-null count  Dtype
---  --
 0   age                   1200 non-null   int64
 1   gender                1200 non-null   object
 2   daily_social_media_hours  1200 non-null   float64
 3   platform_usage        1200 non-null   object
 4   sleep_hours           1200 non-null   float64
 5   screen_time_before_sleep  1200 non-null   float64
 6   academic_performance    1200 non-null   float64
 7   physical_activity       1200 non-null   float64
 8   social_interaction_level  1200 non-null   object
 9   stress_level           1200 non-null   int64
10   anxiety_level          1200 non-null   int64
11   addiction_level         1200 non-null   int64
12   depression_label        1200 non-null   int64
dtypes: float64(5), int64(5), object(3)
memory usage: 122.0+ KB
None
```

Figura 2: importación de librerías e importación del dataset

```
# separar variables (X = datos, y = etiqueta)
X = df.drop("depression_label", axis=1)
y = df["depression_label"]

# Crear carpeta para guardar resultados
os.makedirs("splits", exist_ok=True)

# división 80/20 con semillas fijas
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# guardar archivos
X_train.to_csv("splits/X_train.csv", index=False)
X_test.to_csv("splits/X_test.csv", index=False)
y_train.to_csv("splits/y_train.csv", index=False)
y_test.to_csv("splits/y_test.csv", index=False)

print("Listo")

# Listo
```

Figura 3: Separación de variables y guardado de archivos en carpeta splits

Nota técnica

¿Qué son los splits y su importancia?
Los splits son divisiones de un dataset en subconjuntos (entrenamiento y prueba) que permiten entrenar modelos de inteligencia artificial y evaluar su desempeño con datos no vistos. Son importantes porque evitan el sobreajuste y permiten medir la capacidad de generalización del modelo.

Nombre del dataset:
Teen Mental Health Dataset

Fuente original:
Kaggle

Autor:
Muhammad Shahzad

Proporción usada:
80% entrenamiento / 20% prueba

Semilla utilizada:
random_state = 42

Criterio de división aplicado:
División aleatoria estratificada usando `train_test_split`.

```

import os
print(os.getcwd())
  
```

(x) ✓ 0.0s

`C:\Users\alago\Documents\Platform\0\projects\auge-chihuahua\src`

Python

Figura 4: Nota técnica y localización de archivo

Separación de datos por entrenamiento y pruebas

age	gender	daily_social_r	platform_usa	sleep_hours	screen_time	academic_per	physical	activ-social_interac	stress_level	anxiety_level	addiction_level
13	male	5.1	TikTok	5.3	2.6	2.95	1.2	medium	2	6	10
17	female	5.3	Both	6.8	1.9	3.39	1.6	low	10	6	8
16	female	4.8	Instagram	6.7	1.4	2.44	0.3	low	1	3	1
18	male	2.5	Both	5.7	2.1	3.33	0.6	low	8	4	6
14	male	2.8	Both	6.2	1.2	3.21	1	low	3	10	6
13	male	5	Instagram	5.2	2.6	2.04	1.7	medium	4	4	5
13	male	4	Instagram	4.2	0.9	2.75	1	high	5	4	8
13	male	1.8	Instagram	8.9	1.2	3.67	0.1	medium	2	8	9
13	male	7.1	Both	5.7	2.1	3.52	1.7	low	1	1	3
17	male	5.1	TikTok	5.1	2.9	3.99	0.6	medium	4	2	9
18	female	7.1	Instagram	5.7	0.6	2.9	1.7	medium	3	1	6
17	female	5.3	Instagram	6.6	0.6	3.04	0.1	high	3	7	1
17	male	6.2	Instagram	7.4	0.6	3.38	1.5	low	4	7	9
17	female	5.4	TikTok	7.1	2.5	2.68	1.6	low	3	5	7
17	male	4.7	TikTok	7.2	2.7	2.06	1.4	low	3	1	4
14	male	7.2	TikTok	4.8	1.4	2.36	0.1	low	5	7	1
13	male	2.2	TikTok	5.3	1.4	3.97	0	low	1	10	7
13	male	5.2	Both	5.4	0.8	2.39	2	low	8	3	10
14	female	5.6	TikTok	6.8	2.3	2.66	1.1	high	7	6	2
13	male	2.1	TikTok	5.8	2.7	3.83	1.9	low	4	6	6
15	female	3.6	TikTok	7.1	0.9	2.84	0.3	low	1	9	4
19	male	4.7	Both	8.7	2	3.23	1.7	low	4	10	3
16	male	4.1	Both	5.5	1.9	2.65	1.5	low	5	7	9
15	female	1.1	Instagram	4.6	1.8	2.35	1.1	medium	10	6	6
15	male	2.8	TikTok	6.1	2.9	2.98	1.8	medium	6	3	7
17	male	5.3	Instagram	6.4	2.9	2.42	1.1	low	3	8	3
17	female	5.8	Instagram	4.1	2.9	2.33	0.4	high	9	6	8
16	male	2	Instagram	8.2	1	3.15	0.9	medium	9	7	10
19	male	5.6	TikTok	6.5	1.4	3.19	0	high	9	9	7
16	male	2.3	Both	8	1.9	2.12	0.4	high	7	4	4

Figura 5: Xtest



	A	B	C	D	E	F	G	H	I	J	K	L
1	age	gender	daily_social_r	platform_usa	sleep_hours	screen_time	academic_per	physical_acti	social_interac	stress_level	anxiety_level	addiction_level
2	13	male	2.2	Both	5.8	2	3.63	1.9	low	4	4	10
3	13	male	7.9	TikTok	6	2.7	2.85	0.3	low	9	10	3
4	16	female	5.2	TikTok	8.1	2.1	2.67	1.7	medium	9	10	10
5	19	female	3.3	TikTok	5	2.1	2.04	0.9	high	1	10	9
6	17	female	5	Both	4.9	2.1	2.01	1	low	9	4	9
7	16	male	2	TikTok	4.4	0.7	2.68	0.8	medium	1	4	10
8	19	male	3.6	Instagram	6.5	1.1	3.65	1.1	low	5	9	10
9	16	female	7.1	TikTok	8.8	1.8	3.99	0.8	low	6	10	8
10	14	female	7.2	Both	7	2.3	3.74	0.7	low	8	4	7
11	19	female	1.3	TikTok	6.5	2.1	3.68	1.1	high	7	1	9
12	18	male	2.8	Instagram	6.9	2.3	3.11	0.1	medium	7	1	9
13	17	female	7.5	Both	8.1	2.8	2.58	0.5	medium	2	2	3
14	13	female	7.9	Instagram	7.2	1.5	2.36	0.2	medium	2	6	8
15	16	female	3.5	Both	4.2	1.5	3.98	0.4	medium	1	7	2
16	14	male	5.6	Both	4.5	1.4	2.44	1.2	low	5	10	9
17	16	male	1.8	Instagram	4.9	2.3	2.67	1.4	medium	3	8	6
18	14	male	5.8	Instagram	5.1	2.6	2.06	1.5	medium	7	5	2
19	18	female	2.3	Instagram	8.7	0.6	2.76	1.9	high	4	8	7
20	15	female	6.9	TikTok	8.3	2.4	3.34	1.2	high	2	4	9
21	18	male	5.6	Both	8	2.4	2.95	0	low	2	10	3
22	18	female	1.8	Both	7.8	2	2.67	0.8	low	4	6	3
23	16	male	4.8	Both	6.8	1	2.6	1.1	medium	1	5	6
24	15	female	1.8	Instagram	5.5	1.6	3.29	1.3	medium	6	5	9
25	13	female	5.1	TikTok	4.5	2.7	2.54	1.4	high	2	3	10
26	14	female	4.5	TikTok	4.8	0.9	2.22	0.8	low	1	4	10
27	16	male	4.9	Instagram	5.7	1.2	2.07	0.1	medium	8	2	1
28	13	male	1.6	TikTok	4.3	0.6	3.91	2	medium	5	10	7
29	14	male	6.1	Both	7.6	1.4	2.72	0.9	low	9	3	3
30	18	female	7.5	TikTok	7.5	1.4	3.14	2	low	2	9	2
31	19	male	7.7	TikTok	8.4	2.8	3.43	0.2	medium	7	6	6

Figura 6: Xtrain

Conclusión

La correcta manipulación y preparación de los datos es un aspecto fundamental en el desarrollo de modelos de inteligencia artificial, ya que de ello depende en gran medida la calidad de los resultados obtenidos. A lo largo de este trabajo, se ha demostrado la importancia de dividir un dataset en subconjuntos de entrenamiento y prueba, proceso que permite entrenar modelos de manera adecuada y evaluar su desempeño de forma objetiva. Esta práctica no solo facilita la detección de problemas como el sobreajuste, sino que también asegura que el modelo sea capaz de generalizar y funcionar correctamente con datos nuevos.

El uso de herramientas como Python y bibliotecas especializadas permite realizar este tipo de procesos de manera eficiente y reproducible. En particular, la implementación de una semilla fija en la división de los datos garantiza que los resultados puedan ser replicados, lo cual es esencial en entornos académicos y profesionales. Asimismo, el uso de técnicas como la división estratificada contribuye



a mantener la distribución original de las clases, mejorando la calidad de la evaluación del modelo. el análisis de un dataset relacionado con la salud mental en adolescentes pone en evidencia el potencial de la inteligencia artificial para abordar problemáticas relevantes en la sociedad. Sin embargo, también resalta la importancia de manejar este tipo de información con responsabilidad, considerando aspectos éticos como la privacidad y el uso adecuado de los datos. La combinación de un enfoque técnico con una perspectiva ética resulta clave para el desarrollo de soluciones confiables y socialmente responsables.

Bibliografía

Bishop, C. M. (2006). Gubbi, J., Buyya, R., Marusic, S., & Palaniswami, M. (2013). Internet of Things (IoT): A vision, architectural elements, and future directions. (7).

García, A. &. (2014). Procesamiento digital de señales: Principios y aplicaciones.

Géron, A. (2022). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly Media.

Goodfellow, I. B. (2016). Deep learning. MIT Press.

James, G. W. (2021). An introduction to statistical learning (2nd ed.). Springer.